

Verbessern der Bestandsverwaltung: Statistische Prognose-Optimierung für eine verbesserte Entscheidungsfindung in der Lieferkette

Aberer Raphael, Heinemeyer Janine, Häffner Silas, Saez Mauricio, Phiaphakdy Emilia

ZHAW, School of Management and Law - Design Science (2024-HS)

watsonx

FRANKE

Problemidentifikation (WARUM)

Problem

Das bestehende Prognosesystem von unserem Kunden erstellt eine statistische Baseline auf Grundlage historischer Kundenbestellungen. Diese Baseline wird anschliessend dem Demand Planner zur Verfügung gestellt, der sie überprüft und manuelle Anpassungen vornimmt, sobald neue kommerzielle Informationen (z.B. Aktionen, Rabatte, neue Kunden) verfügbar sind.

Die Genauigkeit der statistischen Prognosebasis ist mit nur etwa 45–50 % **sehr gering**. Diese schwache Leistung zwingt die Demand Planner zu häufigen Eingriffen. Die Demand Planner investieren erheblich viel Zeit in die Überprüfung und **manuelle Anpassung** der Prognosen und trotz dieses hohen Aufwands ist die Verbesserung der Prognosegenauigkeit minimal und bringt im besten Fall nur etwa 2 % zusätzlichen Nutzen.

Der investierte Zeit- und Arbeitsaufwand führt folglich nicht zu nennenswerten Verbesserungen, was auf einen **ineffizienten Prozess** und eine mögliche Fehlallokation wertvoller personeller Ressourcen hinweist.

Motivation

Eine **präzisere** und robustere Prognoselösung würde den Bedarf an umfangreichen manuellen Eingriffen reduzieren und dadurch **Zeit und Ressourcen sparen**. Eine höhere Zuverlässigkeit der Prognosen würde zudem **bessere Entscheidungen** im Bereich Beschaffung und Bestandsmanagement unterstützen.

Forschungsfrage

Wie kann ein verbessertes statistisches Prognosemodell entwickelt werden, damit manuelle Anpassungen minimiert und die Prognosegenauigkeit signifikant zu erhöht werden kann?

Artefakte: [Business Opportunity Statement](#), [Empathy Map](#)

Methodik (WIE)

Wissensdatenbank

Die Grundlage der Designphase bildet die "Knowledge Base" und besteht aus:

- Wissenschaftliche Theorien und dem Kurs Data Science
- Erfahrungen, welche während der IBM Labs und paralleler Kurse im Semester gesammelt wurden
- Meta-Artefakten, die aus Übungen übernommen und angepasst wurden (Peffers et al., 2007)
- Qualitativen Interviews mit Stakeholdern

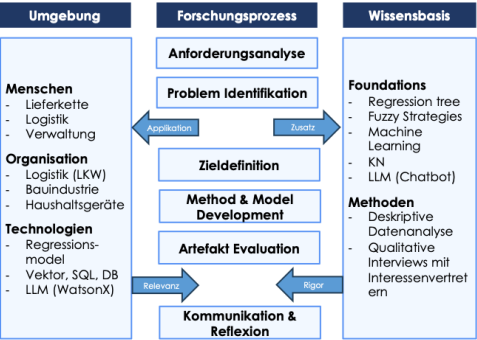
Lean Projektmethodik

- Empathy Map & Stakeholder Analyse
- Sprints
- MVP (Minimum Viable Product)
- Iteration & Demonstration
- Feature Clustering
- Prototyping



Quelle: gamestorming.com/empathy-map

Research Design (WIE)



Quelle: Illustration basiert auf dem Modell von Hevner et al., 2004, S.80-83

Zielsetzungen & Wissensbasis (WAS)

Primärziel

- Entwicklung eines transparenten Bedarfsprognosemodells
- Verbesserung der Prognosegenauigkeit

Sekundärziele

- Reduzierung manueller Anpassungen durch Bedarfsplaner mittels zuverlässigerer statistischer Prognosen und Identifizierung von Faktoren der Nachfragevolatilität zur Verbesserung der Prognosestabilität
- Erstellung erklärbarer Prognosen, die Nutzervertrauen aufbauen vs. aktuellem "Black Box"-Ansatz
- Nutzung externer Faktoren und Bauindikatoren sowie BIP als wirtschaftliche Frühindikatoren

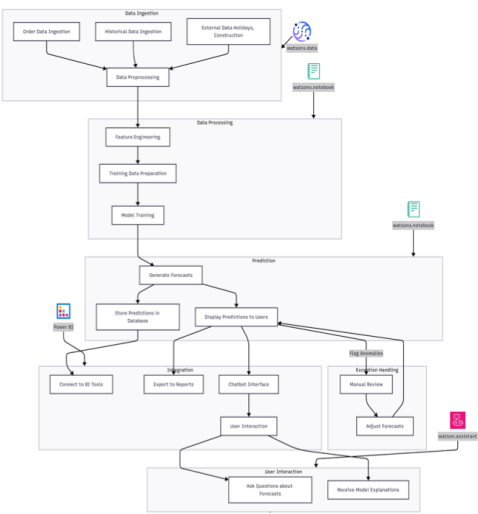
Entwicklung eines Bedarfsprognose-Berichtssystems

- **Trendberichterstattung:** Welche Produktkategorien zeigten erhebliche Nachfrageschwankungen in den letzten drei Monaten? Welche Produkte zeigen konsistente Muster?
- **Jahresberichterstattung:** Wie hat sich die Nachfrage im Jahresverlauf entwickelt? (Veränderungen zum Vorjahr?)
- **Gesamterichterstattung:** Welche Produkte und Märkte erfordern besondere Aufmerksamkeit? Wo treten die grössten Prognosefehler auf?

Visualisierung der Prognoseleistung

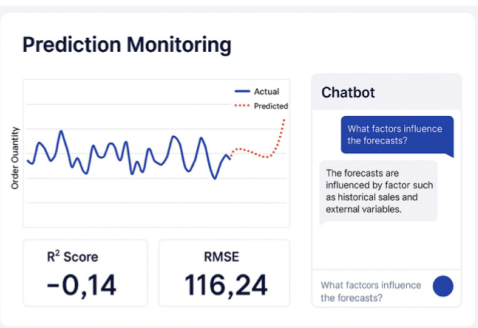
- Metriken der Berichterstattung: Prognosegenauigkeit, Produktkategorie, betroffener Markt & Zeithorizont
- Vergleich zwischen statistischer Basisprognose und tatsächlicher Nachfrage und Transparenz bezüglich Prognosezuverlässigkeit.

Artefakt (WAS)



Quelle: Mermaid - Visualisierung der Prozessarchitektur des Bedarfsprognose-Systems

Ergebnisse - Chatbot / Dashboard



Quelle: Chat GPT - Visualisierung des UI

Übersicht der Layer

Datenübernahme

Sammelt Daten aus Quellen wie Auftragsdaten, Historischen Daten und Externen Faktoren (Feiertage, Baugewerbe). Daten werden mit Tools wie `watsonx.data` für Bereinigung und Vorbereitung aufgenommen und vorverarbeitet.

Datenverarbeitung

Transformiert Rohdaten in strukturierte Formate durch Feature Engineering und Trainingsdatenvorbereitung. Verwendet `watsonx.notebook` für codebasierte Vorverarbeitung und Modelltrainingsaufgaben. Modelle werden mit Frameworks wie AutoAI oder massgeschneiderten Modellen trainiert.

Vorhersage

Trainierte Modelle generieren Prognosen basierend auf eingehenden Daten. Vorhersagen werden in einer Datenbank (`watsonx.data`) gespeichert und für Benutzer visualisiert. Tools wie `watsonx.notebook` erstellen Vorhersagen und liefern Ergebnisse.

Integration

Verbindet Vorhersagen mit externen Systemen wie Power BI für Visualisierung und Berichterstattung. Beinhaltet eine Chatbot-Schnittstelle (Watson Assistant) für die Interaktion mit Endnutzern.


User Interaktion

Benutzer können über einen Chatbot mit dem System interagieren, um Fragen zu Prognosen zu stellen und Erklärungen zu erhalten. Ermöglicht Bedarfsplanern, Modellvorhersagen zu verstehen und damit zu interagieren.

Umgang mit Ausnahmen (Exception Handling)

Markiert autom. Anomalien und ermöglicht manuelle Überprüfung und Anpassungen durch einen Ausnahmebehandlungsprozess. Abgewickelt über Tools wie `watsonx.notebook` für Anomalie-Erkennung und Watson Assistant für Interaktion.

Ergebnisse - Prediction Accuracy



Fazit

Watsonx-basierte Prognoseoptimierung

Die entwickelten Prognoselösungen zeigen durch die Integration statistischer Modelle das **Potenzial**, die **Bedarfsplanung** bei Franke nachhaltig zu **transformieren**. Trotz aktuell bestehender Limitationen hinsichtlich der Prognosegenauigkeit bietet ein in die **watsonx-Systemlandschaft integrierter Algorithmus** bereits eine erste Grundlage für zukünftige Optimierungen und iterative Verbesserungsprozesse.

Der **implementierte Chatbot** verfolgt dabei das Ziel, die Transparenz zu erhöhen und den Anwendern die Möglichkeit zu geben, **Prognoseentscheidungen nachvollziehbar** zu treffen. Die zusätzliche **Integration externer Einflussfaktoren mithilfe von `watsonx.data`** verspricht zudem Verbesserungen hinsichtlich der Prognosequalität und einer realistischeren Abbildung der Marktdynamiken.

Herausforderungen

Aktuell bestehen jedoch noch Herausforderungen bezüglich der konkreten algorithmischen Umsetzung und deren Output-Qualität; welche primär durch **Limitationen in der verfügbaren Datenbasis** bedingt sind. Daher wurde ein Schwerpunkt auf Verfahren zur Ausreissererkennung und -behandlung gelegt, um die generelle Datenqualität und Robustheit der Prognosemodelle zu steigern.

Entwicklungspotenzial und Ausblick

Trotz der zeitlichen Beschränkungen könnte in den nachfolgenden Entwicklungsphasen das Modell durch **Integration zusätzlicher interner Unternehmensdaten sowie externer Marktindikatoren** gezielt und kontinuierlich verfeinert werden. Bei ausreichender Datenverfügbarkeit und -qualität könnte die entwickelte Methodik flexibel **auf andere Produktgruppen sowie Geschäftsbereiche übertragen** werden.

Ebenso könnte eine weitere **Verbesserung der algorithmischen Transparenz** angestrebt werden, um die Interpretierbarkeit der Prognosen zu steigern und damit sowohl die Benutzerakzeptanz als auch das Vertrauen in die generierten Vorhersagen nachhaltig zu festigen.

Zusammenfassung

Insgesamt adressiert die aktuelle Lösung gezielt die Kernproblematik der ineffizienten manuellen Prognoseanpassungen und versucht damit das notwendige Fundament für eine datengesteuerte Bedarfsplanung zu schaffen. Dies verspricht nicht nur eine deutlich **höhere Prognosezuverlässigkeit, sondern auch eine signifikante Optimierung des Ressourceneinsatzes bei Franke**. Wenngleich das Konzept bereits wesentliche Aspekte des Lösungsansatzes definiert, ist die finale, technische Implementierung noch nicht abschliessend erfolgt und bedarf noch einigen Anpassungen.



FORECASTING FOR INVENTORY

AGENDA

1. Problem statement
2. Our Approach & Solution
3. Live Demo
4. Solution & Enhancements
5. Conclusion and Next Steps



PROBLEM STATEMENT



Problem

Demand Planners invest a lot of time in manually adjusting the statistical forecast baseline.



Painpoints

- Statistical forecast baseline accuracy is 45-50%
- Statistical forecasting methodology is currently opaque

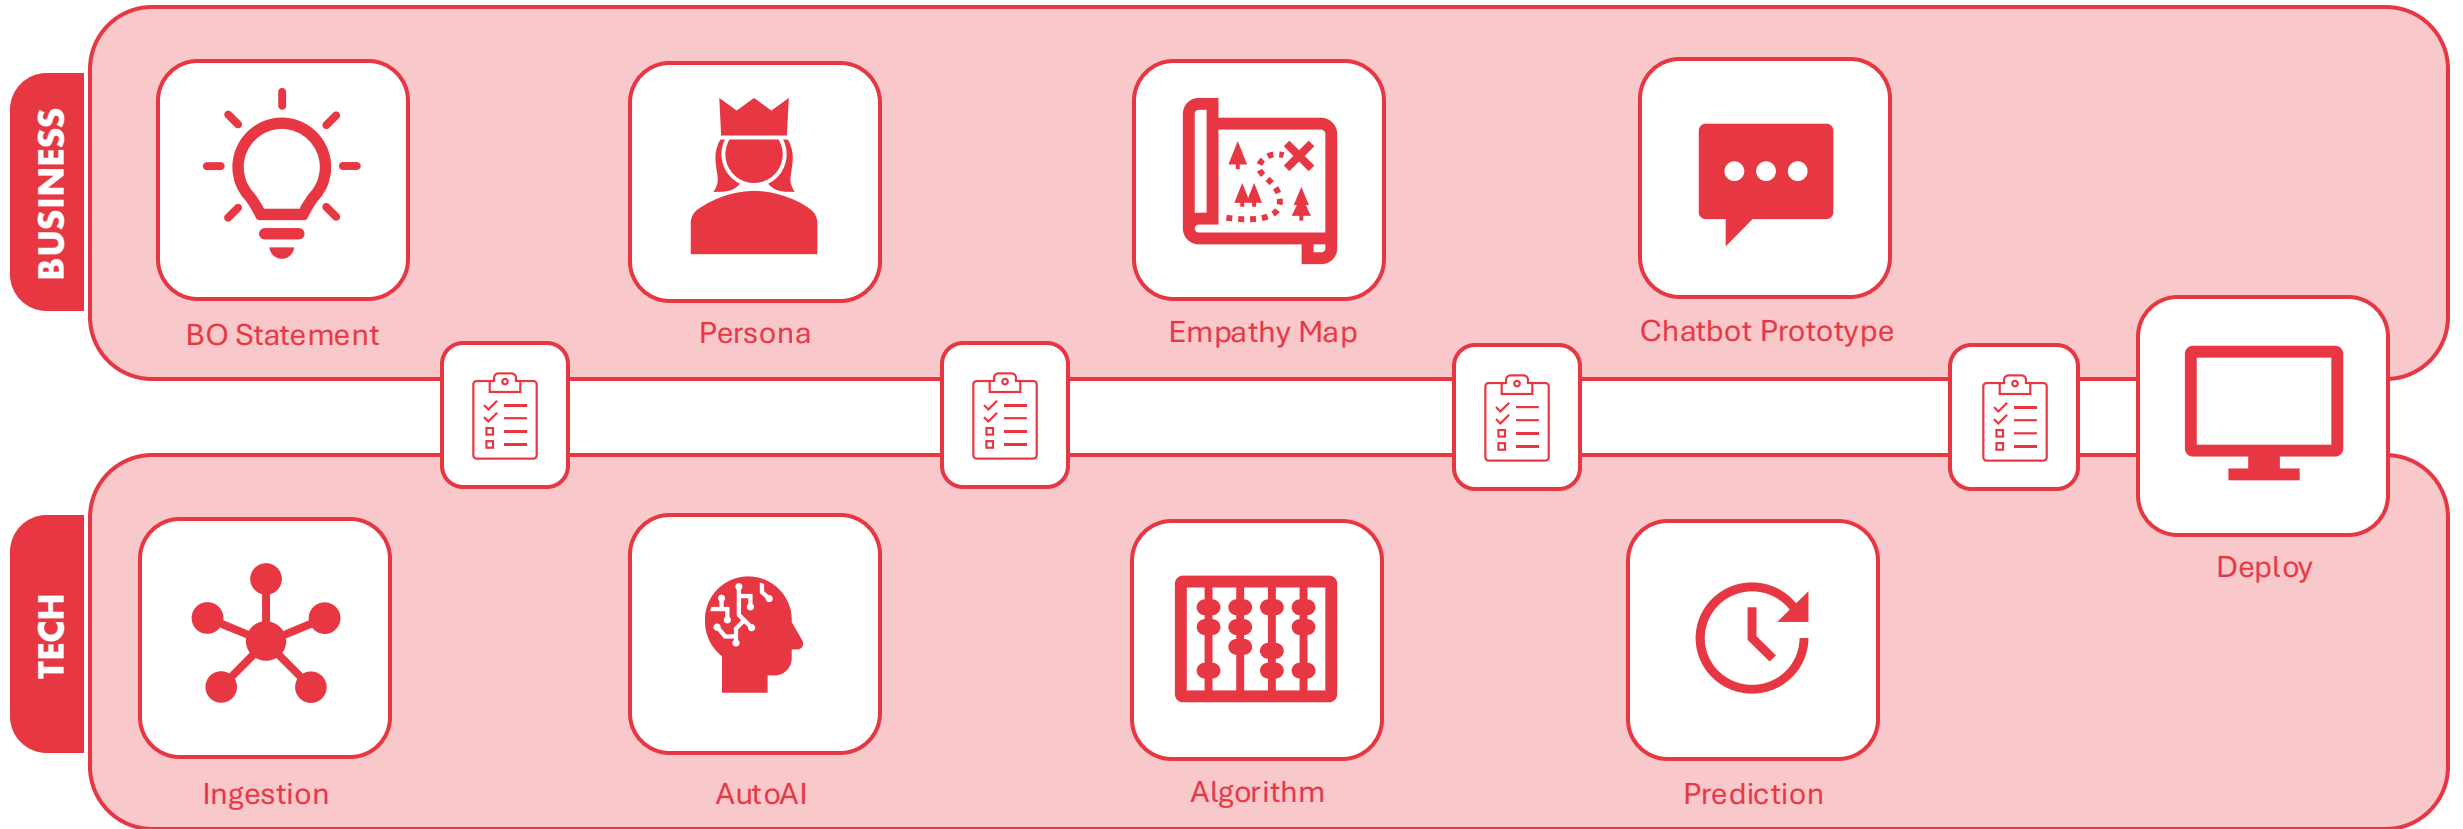


Goal of the solution

Good baseline accuracy
→ few adjustments for the demand planner

HOW?

OUR APPROACH & SOLUTION

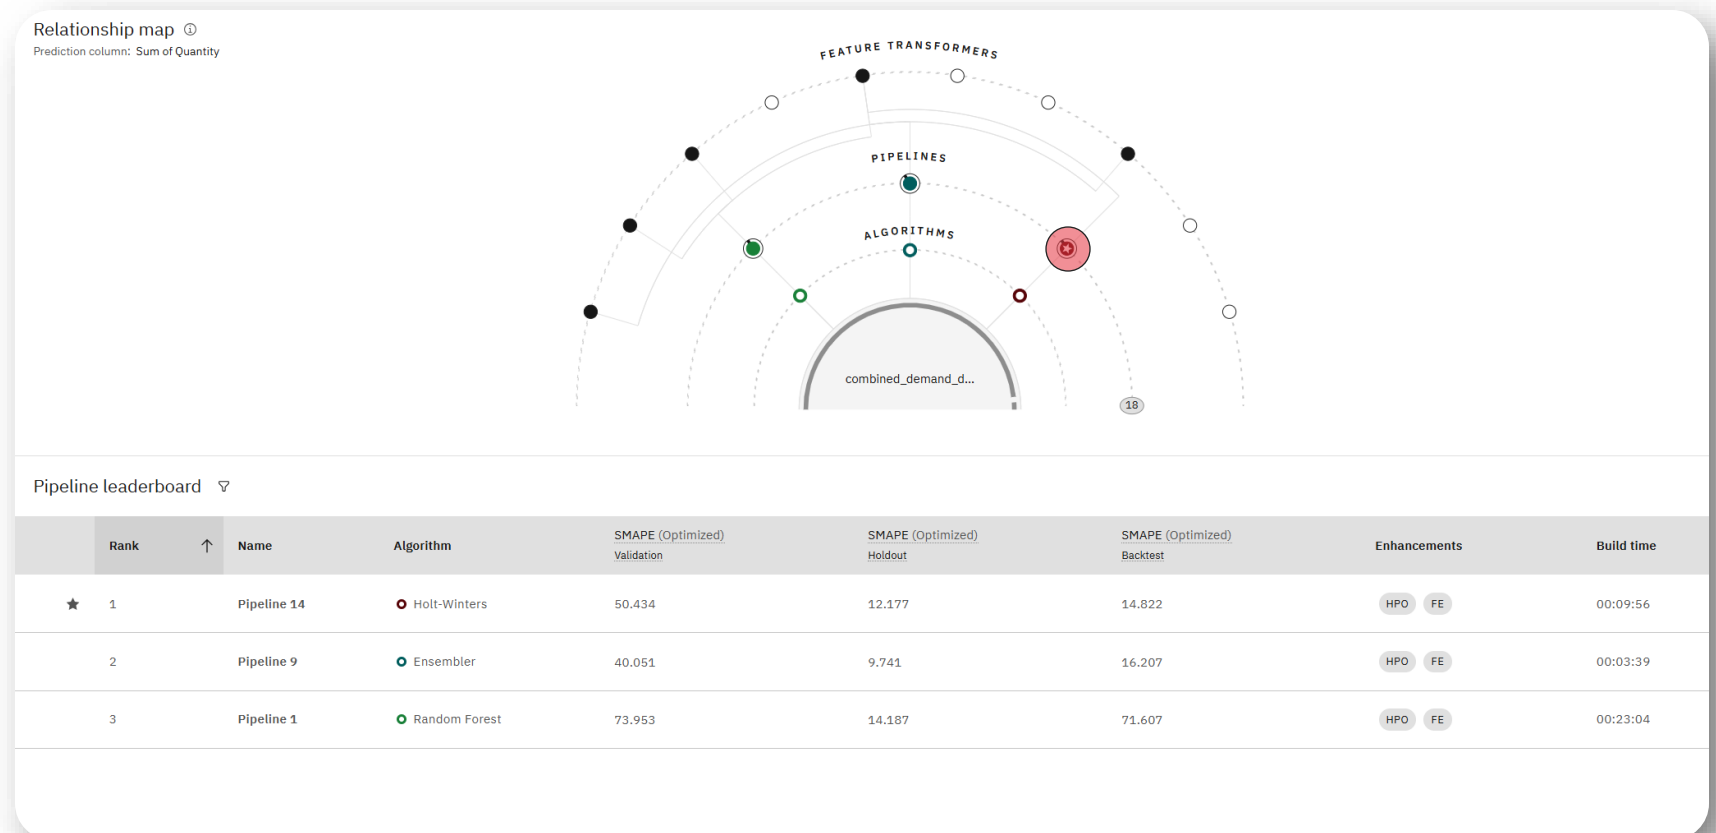


OUR APPROACH & SOLUTION

TAKEAWAYS

- Iterations
- Fail fast
- Continuous feedback


SPOTLIGHT: AUTO AI



LIVE DEMO


Value Creation

↑ BUSINESS VALUE



- Reduction of manual interventions
- Reduction of forecasting time
- Reduced working capital requirements
- Long-term inventory cost reduction

① PROBLEM SOLUTION



- Transparency through chatbot
- Improved forecast accuracy
- Standardized methodology making manual interventions easier

WEIGHTED ACCURACY

+15.3 p.p.

FLOP

115.0311.211

76.4% → 91.7%.

TOP

115.0521.438

KPI Measurement

KPI	TARGET	STATUS
SMAPE (Good Accuracy Products)	< Franke	+ 1.74 %
SMAPE (Average Accuracy Products)	< Franke	+ 7.05 .%
SMAPE (Bad Accuracy Products)	< Franke	- 48.48 %
Challenge Products Identified	-	3 Products

KPI Measurement

1.12 < 1.25

Highest ROI: Good Accuracy products
deliver maximum cost savings
through volume leverage

Category	MAE (Units)	RMSE (Units)	Stability
Good Accuracy	384	476	1.22
Average Accuracy	99	104	1.05
Bad Accuracy	294	319	1.09

SOLUTION & ENHANCEMENTS

SCALING



9 key-pairs
→ all products

ERROR HANDLING



Chatbot writeback on
prediction with user
interaction

WATSONX.DATA



Data Integration Pipeline
connects external &
historical data sources

Reflection

Process Reflection – Lean Methodology:

- Agile & MVP approach
- Iterative development
- Stakeholder Meetings
- Empathy mapping insights



Technical Challenges:

- Data quality issues
- WatsonX integration complexity
- Key technical lessons learned




Data-Driven Approach:

- Through data analysis importance
- Data preparation challenges
- Cross-functional collaboration value
- Early metric establishment




What we would do differently

Methodological



More time
Start simple
Clearer metrics

Technical



**Comprehensive
approach**
Improve tooling

Stakeholder



Broder range end users
Get feedback early

Conclusion

Key Achievements:



- Enhanced forecast accuracy
- Improved transparency with explainable AI
- Developed user-centric interfaces

Business Impact:



- Scalable solution for add. products & markets
- Time savings for demand planners



Future Roadmap:

- Expand data sources & markets
- Implement continuous learning
- Enhance algorithm transparency

THANK YOU!